

2026 深圳国际金融科技大赛

数据分析赛道 · 题五

基于因果横截面排序、LambdaRank 与换手约束的股票评分方案

790 万

训练样本行

0.3818

三折 OOF 综合分

0.2034

平均换手率

160 万

测试预测行

执行摘要

本方案面向每日 4,650 只股票的横截面评分。核心模型由全历史 LambdaRank (60%)、近两年 ATR 增强 LambdaRank (20%) 及 LightGBM/Ridge 回归组合 (20%) 构成；各组件先做同日排名，再使用因果 EMA 与 Top 集合滞回控制换手。


在 2022、2023、2024 三个严格时间顺序验证折上，最终方案综合分分别为 0.4482、0.3732、0.3240，等权均值 0.3818；相对单一 LambdaRank，均分提高 0.0038、最差折提高 0.0082、换手下降 0.0089。

重要声明：以上均为训练集 walk-forward OOF 指标。隐藏测试标签不可用，项目没有推断、伪造或报告测试集成绩。最终 CSV 仅通过结构与数值完整性检查。

1. 数据介绍

数据为固定股票面板的日频量价记录，字段包括证券代码、交易日、开高低收、成交量、成交额、涨跌停标记；训练集额外提供下一交易行收益 `y_ret_1d`。原始 CSV 始终只读，中间大文件按年写入 D 盘 Parquet。

数据集	日期范围	行数	交易日	股票数	标签
训练集	2018-01-02 ~ 2024-12-31	7,900,350	1,699	4,650	真实 <code>y_ret_1d</code>
测试集	2025-01-02 ~ 2026-06-08	1,599,600	344	4,650	无标签



数据质量与边界

主键无缺失、无重复；OHLC 关系、非负成交量/额与涨跌停二值约束全部通过。训练集价格缺失约 14.4%，主要来自股票未上市或停牌形成的面板空洞；标签缺失率由 2018 年 26.2% 降至 2024 年 2.8%。模型保留缺失语义，树模型原生处理 NaN，Ridge 的横截面 z-score 缺失映射为中性 0。

2. 描述性分析

年份	有效标签	均值	波动	1%分位	99%分位	缺失率
2018	833,573	-0.0013	0.0279	-0.0945	0.0998	26.2%
2019	864,295	0.0013	0.0275	-0.0761	0.1000	23.8%
2020	900,033	0.0009	0.0311	-0.0907	0.1000	20.3%
2021	975,147	0.0010	0.0306	-0.0755	0.1001	13.7%
2022	1,029,017	-0.0002	0.0305	-0.0809	0.1000	8.6%
2023	1,062,411	0.0002	0.0242	-0.0585	0.0931	5.6%
2024	1,094,055	0.0003	0.0354	-0.0992	0.1004	2.8%


关键观察

- 收益分布高度尖峰且存在长尾；中位数多为 0，2024 年极端值范围扩大，因此回归误差不是唯一有效目标。
- 赛题得分同时奖励 Rank IC、Top 组合相对全市场的年化超额及低换手，模型应优化横截面次序而非收益点预测精度。
- 每日股票数固定，但可用量价与标签随上市、停牌状态变化；计算横截面统计时保留覆盖率，不以 0 冒充原始缺失。
- 涨停股票在组合评价中不可买入；后处理只重排非涨停股票的唯一序数分值，保持每日评分分布稳定。

评价函数

综合分 = $0.4 \times \text{平均 Rank IC} + 0.3 \times \text{Top10\% 相对全市场年化超额} + 0.3 \times (1 - \text{平均换手率})$ 。本地实现对官方脚本全部分支达到 $1e-12$ 以内一致性。

3. 模型分析（一）：特征与验证设计



基础特征覆盖收益、波动、K线形态、成交活跃度、流动性、价格位置与均线结构，并在每日截面形成 percentile rank 和 z-score；另构造市场等权收益、截面波动、上涨比例及成交额状态。Phase 13 增加 RSI、MACD、ATR、Bollinger、OBV-like、VWAP 代理、趋势效率与突破等 32 个因果候选。


高级特征只在 2018–2021 筛选，2022–2024 仅作留出验证。覆盖率、|IC|、ICIR、逐年同号、家族上限与 0.90 相关性阈值共同锁定 16 项；完整 ranker 仅验证证据最强的 ATR 家族，避免大规模事后搜索。

时间序列验证与防泄漏

验证折	训练期	Purge	验证期
2022	2018-01-02 ~ 2021-12-30	1个交易日	2022全年
2023	2018-01-02 ~ 2022-12-29	1个交易日	2023全年
2024	2018-01-02 ~ 2023-12-28	1个交易日	2024全年

所有时序特征仅使用 t 及以前；横截面与市场特征只使用同日全体股票；标签在特征物化后按键连接。验证折各自重置后处理状态，而生产推理使用训练尾部状态连续进入测试期。


3. 模型分析（二）：模型比较与最终方案



方案	Rank IC	年化超额	换手率	综合分
Ridge	0.0609	0.1151	0.8762	0.0960
LightGBM	0.0794	0.2057	0.5041	0.2422
LGB+换手控制	0.0821	0.2707	0.2934	0.3260
LGB/Ridge融合	0.0844	0.3014	0.2778	0.3408
LambdaRank	0.1042	0.3333	0.2123	0.3780
最终融合	0.1056	0.3353	0.2034	0.3818

最终嵌套权重：基础 LambdaRank 60% + 近两年 ATR LambdaRank 20% + 回归 sleeve 20%；回归 sleeve 内为 LightGBM 65% + Ridge 35%。三个端点对历史 OOF 的八项官方指标复刻差均为 0，融合后再统一执行 alpha=0.5、退出缓冲 15% 的因果后处理。

3. 模型分析（三）：稳定性与市场状态



所有方案在 2022→2024 均出现分数回落，主要风险是市场状态漂移和后期换手抬升。近两年 ATR 模型在低波动状态更稳且换手更低，但在上涨、下跌状态均落后基础 LambdaRank，因此没有建立独立 regime 路由，而是只给予 20% 稳健性权重。

最终融合逐折分数 0.4482 / 0.3732 / 0.3240，最差折比基础 LambdaRank 提高 0.0082；标准差由 0.0649 降至 0.0626，平均换手由 0.2123 降至 0.2034。改进幅度有限但方向一致，故采用简单、可审计的固定权重。

4. 应用验证与 5. 产品思路

生产推理链路



应用检查	结果
训练尾部 warm-up	250 日 / 1,162,500 行
测试期覆盖	344 日 / 1,599,600 行
状态跨边界	4,650 EMA; 459 Top成员
特征 schema	47 / 49 / 47 / 36 全部一致
Submission	键集合、行序、有限值、CSV回读全部通过

产品化：低换手股票评分与组合候选服务

面向资管投研或财富管理内部系统，每日输出全市场标准化评分、Top 候选池、换手预算和风险提示。评分层负责可比的横截面排序；组合层结合涨停不可买、持仓缓冲及客户自定义行业/集中度约束；解释层展示主要特征族、历史稳定性和本次入选/退出原因。

上线前需增加真实交易成本、停牌与成交容量、行业中性、公司行动、成分存续偏差及实时数据延迟测试。本赛题结果是离线研究证据，不构成收益承诺或投资建议。

6. 总结结论与最终复现

- 1 排序目标优于同配置回归：LambdaRank 把平均综合分由 0.2422 提升至 0.3780。
- 2 换手控制是核心增量：固定因果 EMA 与持仓缓冲显著降低换手，且未使用未来信息。
- 3 最终融合的提升来自互补而非复杂度：60/20/20 固定权重同时改善均值、最差折与换手。
- 4 测试推理完整复用锁定模型，连续传递状态；最终 CSV 结构完整，但隐藏测试成绩未知。

一键复现顺序

01_check_data.py → 02_audit_labels.py → 03_build_features.py
04_build_cross_sectional.py → 05_build_test_features.py → 06_build_cv.py
07_check_evaluator.py → 08_train_baseline.py → ... → 16_finalize_model.py
17_predict_test.py → 18_build_submission.py → 19_build_final_report.py

关键交付哈希

产物	SHA-256
训练集.csv	E9D23E87F7E1F9439F28F7DD951D129EA49EAACDA5AD650DA8576A830A6DEAC9
测试集_X.csv	DCEFFBF68BBAB07A254BC6CAA4D8A1E33DE8DE9C15489D936C5D15020DBFA90F
Phase17 Parquet	FAD7277364F2642871337DC3035C9F20988D6FC93881C79DEA46632A262B74EB
Submission CSV	19125DE77D0726A23A5E9E209C03960F53EC1E69D312D0A2DD32A0BA2A274865